Modern Storages and Data Warehousing
Week 6 - ETL

Попов Илья, i.popov@hse.ru

1 - Домашнее задание

2 - Задачка с собеса

Задачка с собеса

〉 У нас есть Clickhouse

〉 Особенности Clickhouse как СУБД - он очень не любит одиночные insert / update / delete, но при этом очень быстро делает group by

〉 У нас есть потребность считать агрегаты с большого объема данных - скажем, с терабайта. Clickhouse такие операции очень любит.

〉 Но данные активно меняются / дообогащаются атрибутами, что создает потребность делать много update-операций;

〉 Вопрос: можем ли мы простроить ETL так, чтобы не использовать update / delete? Если да - то как?

Recap прошлых занятий

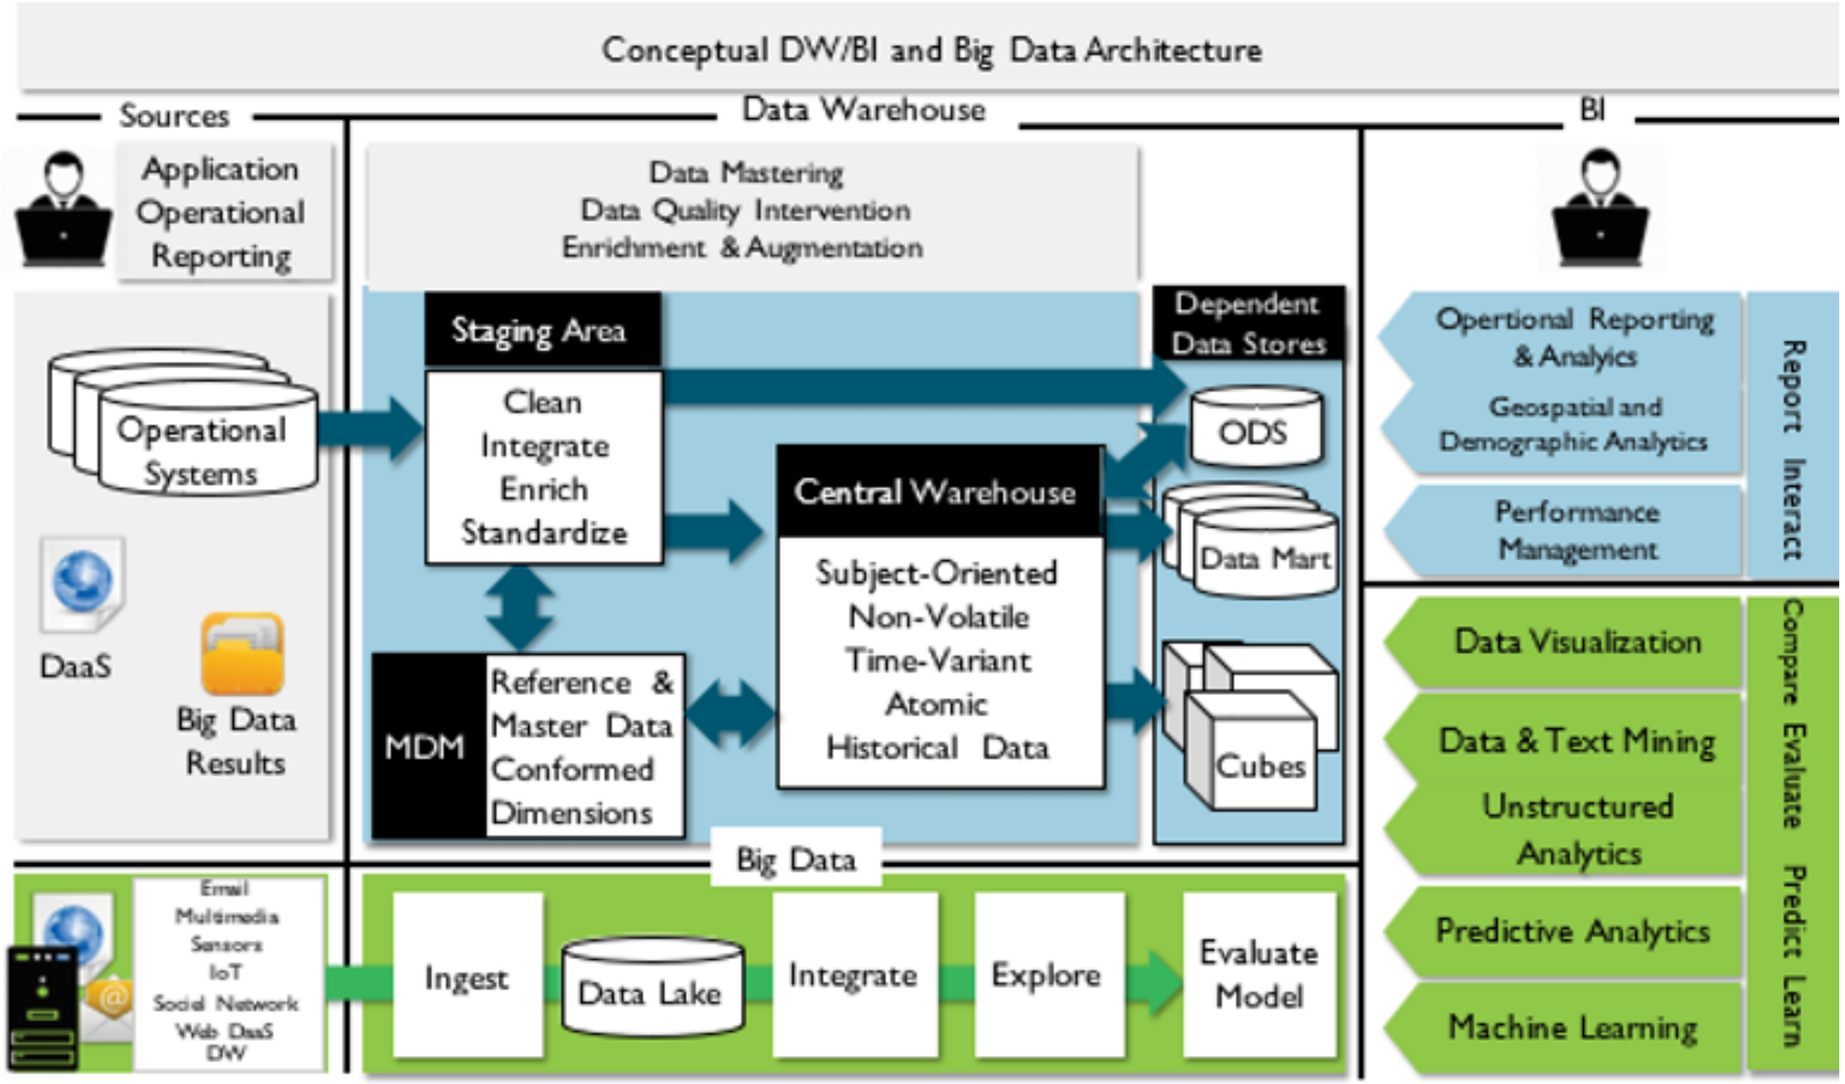

Figure 5: Date Warehouse Concept

3 - ETL

Что такое ETL

ETL (Extract, Transform, Load) - это класс процессов управления данными. Он состоит из:

〉 **Извлечение данных (Extraction - E)** - из одного или нескольких источников и подготовка их к преобразованию (загрузка в промежуточную область, проверка данных на соответствие спецификациям и возможность последующей загрузки в ХД);

〉 **Трансформация данных (Transform - T)** - преобразование форматов и кодировки, агрегация и очистка;

〉 **Загрузка данных (Load - L)** - запись преобразованных данных, включая информацию о структуре их представления (метаданные) в необходимую систему хранения или витрину данных.

Какие бывают ETL

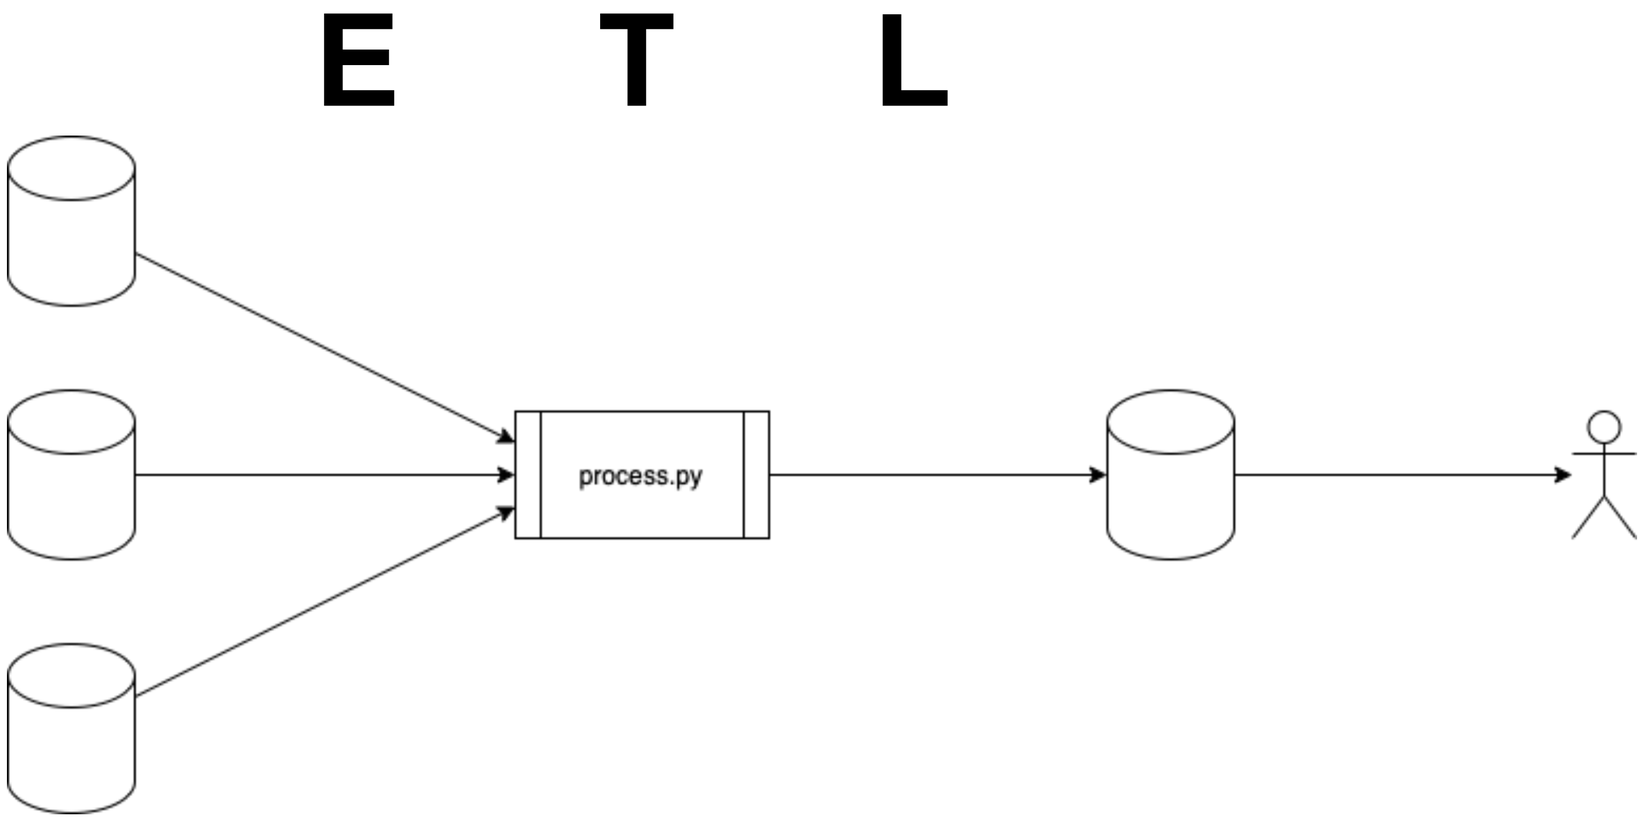

Какие бывают ETL

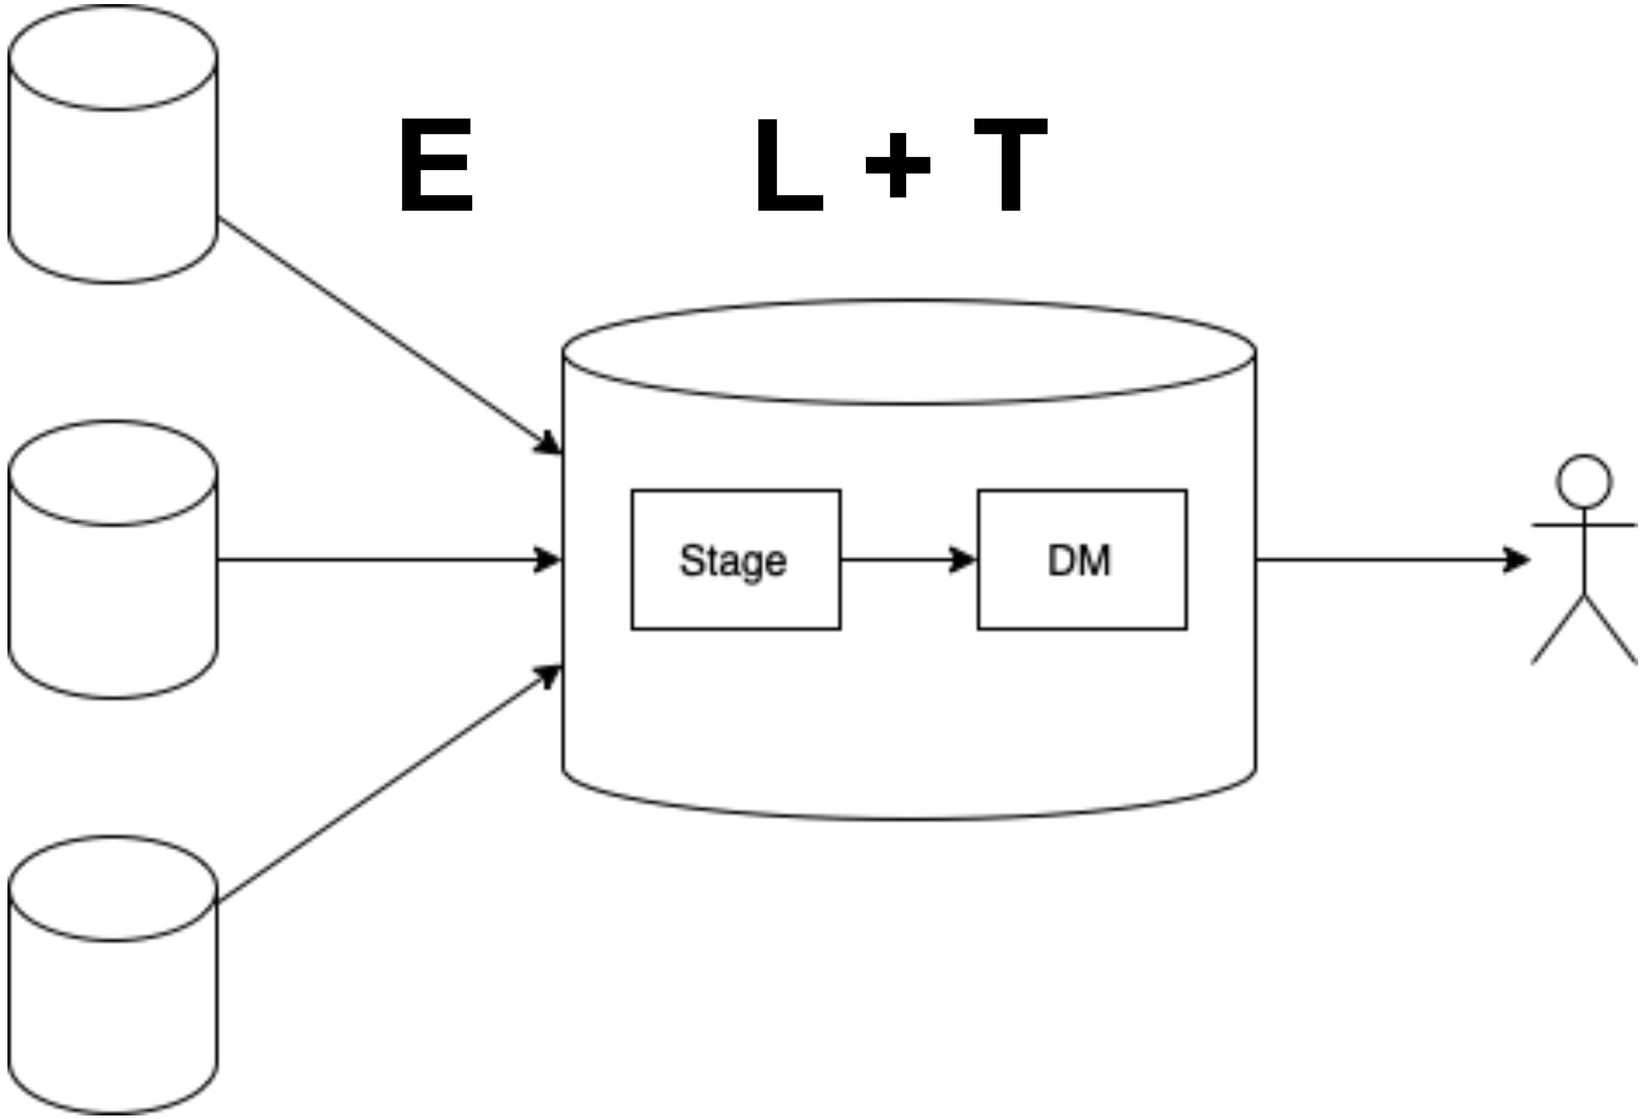

Свойства ETL-процесса

Мы с вами будем говорить про 3 свойства разных видов ETL:

- Идемпотентность
- Delete Policy
- Change Tracking

Идемпотентность

> Идемпотентность - гарантия того, что при повторном применении трансформации к данным результат будет таким же, что и при первом.

Это свойство может гарантироваться только в случае, когда на вход подаются одинаковые данные.

Возможные значение:

- True
- False

Delete Policy

> Delete Policy определяет способ обработки факта удаления данных на источнике при трансформации.

Возможные значения:

〉 **Never** - данные из целевой таблицы не могут быть удалены в штатном режиме работы даже при их удалении с источника

〉 **Delete** - удаление данных на источнике приводит к удалению данных в целевой таблице

〉 **Delete on backfill** - удаление данных может произойти только при историческом пересчете

Change Tracking

> Change Tracking определяет, выполняется ли построение истории изменения объекта по его идентификатору или нет. Существуют различные способы сохранения этой истории.

Возможные значения:

- No tracking
- Overwrite
- History
- Accumulate

Snapshot

Полная перезапись таблицы из источников.

Snapshot

Требования к целевой таблице:

〉Никаких

Когда можно:

〉Маленькие таблицы

〉Нужно хранить только текущее состояние

Когда нельзя:

〉Большие таблицы (1M+ rows)

Snapshot

Требования к целевой таблице:

〉Никаких

Когда можно:

〉Маленькие таблицы

〉Нужно хранить только текущее состояние

Когда нельзя:

〉Большие таблицы (1M+ rows)

Вопросы:

〉Идемпотентность?

〉Delete Policy?

〉Change Tracking?

Snapshot

Требования к целевой таблице:

〉Никаких

Когда можно:

〉Маленькие таблицы

〉Нужно хранить только текущее состояние

Когда нельзя:

〉Большие таблицы (1M+ rows)

Вопросы:

〉Идемпотентность
True

〉Delete Policy
Delete

〉Change Tracking
Overwrite

Periodic Snapshot

Загружаем обновления за последний период с некоторой гранулярностью: час, день, неделя, месяц, квартал, год и т.д.

Periodic Snapshot за 2020-01-02

Данные в целевой таблице

dt=2020-01-01	id=1	v=10
dt=2020-01-01	id=2	v=20
dt=2020-01-01	id=3	v=30

Новые данные

dt=2020-01-02	id=1	v=15
dt=2020-01-02	id=3	v=30
dt=2020-01-02	id=4	v=40

Результат

dt=2020-01-01	id=1	v=10
dt=2020-01-01	id=2	v=20
dt=2020-01-01	id=3	v=30
dt=2020-01-02	id=1	v=15
dt=2020-01-02	id=3	v=30
dt=2020-01-02	id=4	v=40

Periodic Snapshot

Требования к целевой таблице:

〉 Должно быть поле с датой загрузки

〉 Может быть партицирована

Когда можно:

〉 Мало данных

〉 Надо знать состояние сущности с какой-то гранулярностью

Когда нельзя:

〉 Большие таблицы, т.к. избыточность

Periodic Snapshot

Требования к целевой таблице:

〉Должно быть поле с датой загрузки

〉Может быть партицирована

Когда можно:

〉Мало данных

〉Надо знать состояние сущности с какой-то гранулярностью

Когда нельзя:

〉Большие таблицы, т.к. избыточность

Вопросы:

〉Идемпотентность?

〉Delete Policy?

〉Change Tracking?

Periodic Snapshot

Требования к целевой таблице:
〉Должно быть поле с датой загрузки
〉Может быть партицирована

Когда можно:
〉Мало данных
〉Надо знать состояние сущности с какой-то гранулярностью

Когда нельзя:
〉Большие таблицы, т.к. избыточность

Вопросы:
〉Идемпотентность
True
〉Delete Policy
Delete on backfill
〉Change Tracking
Accumulate

Append

Старые данные не меняются. Новые данные дозаписываются.

Append

Данные в целевой таблице

dt=2020-01-01	id=1	v=10
dt=2020-01-01	id=2	v=20
dt=2020-01-01	id=3	v=30

Новые данные

dt=2020-01-02	id=1	v=15
dt=2020-01-02	id=3	v=30
dt=2020-01-02	id=4	v=40

Результат

dt=2020-01-01	id=1	v=10
dt=2020-01-01	id=2	v=20
dt=2020-01-01	id=3	v=30
dt=2020-01-02	id=1	v=15
dt=2020-01-02	id=3	v=30
dt=2020-01-02	id=4	v=40

Append

Требования к целевой таблице:

〉Никаких

Когда можно:

〉Данные не меняются после записи

〉Для каких-то целей нужен лог изменений

Когда нельзя:

〉При большом кол-ве изменений таблица будет быстро расти

〉Может потребоваться TTL

Вопросы:

〉Идемпотентность?

〉Delete Policy?

〉Change Tracking?

Append

Требования к целевой таблице:

〉Никаких

Когда можно:

〉Данные не меняются после записи

〉Для каких-то целей нужен лог изменений

Когда нельзя:

〉При большом кол-ве изменений таблица будет быстро расти

〉Может потребоваться TTL

Вопросы:

〉Идемпотентность
False

〉Delete Policy
Never

〉Change Tracking
Accumulate

Insert by key

Если появляются новые данные - они добавляются в таблицу. Старые данные не меняются. При удалении из источника данные не удаляются.

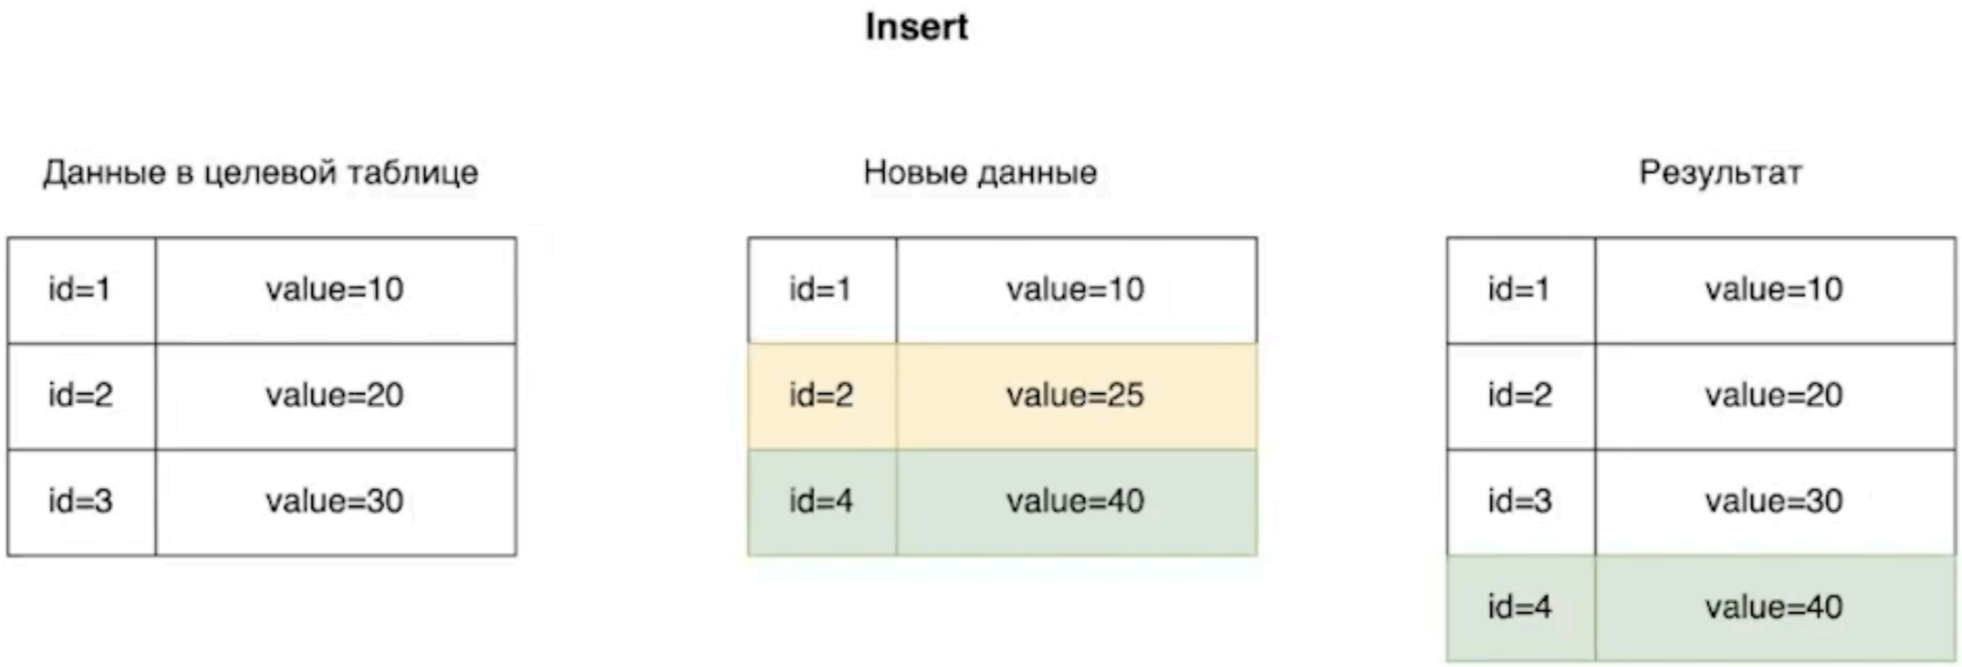

Insert by key

Требования к целевой таблице:

〉Нужен уникальный ключ

Когда можно:

〉Данные могут меняться за произвольную глубину

〉Нужно хранить только первое состояние

Когда нельзя:

〉Нет уникального ключа

Insert by key

Требования к целевой таблице:

〉Нужен уникальный ключ

Когда можно:

〉Данные могут меняться за произвольную глубину

〉Нужно хранить только первое состояние

Когда нельзя:

〉Нет уникального ключа

Вопросы:

〉Идемпотентность?

〉Delete Policy?

〉Change Tracking?

Insert by key

Требования к целевой таблице:

〉Нужен уникальный ключ

Когда можно:

〉Данные могут меняться за произвольную глубину

〉Нужно хранить только первое состояние

Когда нельзя:

〉Нет уникального ключа или его тяжело брать

Вопросы:

〉Идемпотентность
True

〉Delete Policy
Never

〉Change Tracking
No tracking

Upsert

Если появляются новые данные - они добавляются в таблицу. Старые данные таблицы обновляются из новых по ключу. При удалении из источника данные не удаляются.

Upsert

Требования к целевой таблице:

〉Нужен уникальный ключ

Когда можно:

〉Данные могут меняться за произвольную глубину

〉Нужно хранить текущее состояние

Когда нельзя:

〉Нет уникального ключа

Upsert

Требования к целевой таблице:

〉Нужен уникальный ключ

Когда можно:

〉Данные могут меняться за произвольную глубину

〉Нужно хранить текущее состояние

Когда нельзя:

〉Нет уникального ключа

Вопросы:

〉Идемпотентность?

〉Delete Policy?

〉Change Tracking?

Upsert

Требования к целевой таблице:

〉Нужен уникальный ключ

Когда можно:

〉Данные могут меняться за произвольную глубину

〉Нужно хранить текущее состояние

Когда нельзя:

〉Нет уникального ключа

Вопросы:

〉Идемпотентность
True

〉Delete Policy
Never

〉Change Tracking
Overwrite

History по SCD2

History SCD2

Данные в целевой таблице

id=1	name=a	v=10	from=2019-01-01	to=2019-12-31
id=1	name=a	v=10	from=2020-01-01	to=9999-12-31

Новые данные за 2020-02-01

id=1	name=a	v=20
id=2	name=b	v=15

Результат

id=1	name=a	v=10	from=2019-01-01	to=2019-12-31
id=1	name=a	v=10	from=2020-01-01	to=2020-01-31
id=1	name=a	v=20	from=2020-02-01	to=9999-12-31
id=2	name=b	v=15	from=2020-02-01	to=9999-12-31

Берется срез изменений за определенную дату.

На основе этого среза изменяются или создаются сроки в исходной таблице.

History по SCD2

Требования к целевой таблице:

〉Нужен уникальный ключ

Когда можно:

〉Нужно отслеживать историю изменения атрибутов

〉Чаще всего применяется для справочников

Когда нельзя:

〉При большом количестве изменений таблица быстро растет в размере

History по SCD2

Требования к целевой таблице:

〉Нужен уникальный ключ

Когда можно:

〉Нужно отслеживать историю изменения атрибутов

〉Чаще всего применяется для справочников

Когда нельзя:

〉При большом количестве изменений таблица быстро растет в размере

Вопросы:

〉Идемпотентность?

〉Delete Policy?

〉Change Tracking?

History по SCD2

Требования к целевой таблице:

〉Нужен уникальный ключ

Когда можно:

〉Нужно отслеживать историю изменения атрибутов

〉Чаще всего применяется для справочников

Когда нельзя:

〉При большом количестве изменений таблица быстро растет в размере

Вопросы:

〉Идемпотентность
True

〉Delete Policy
Never

〉Change Tracking
History

Особенности времени

У нас есть 2 вида времени:

〉 **Бизнес-время** - время актуальности данных с точки зрения бизнеса; при получении данных с бизнес-временем мы можем говорить, что они актуальны на указанное бизнес-время;

〉 **Техническое время** - реальное время на сервере при получении партии данных;

Свойства времен:

〉 Техническое время монотонно возрастает - мы не можем получать данные в прошлом

〉 Бизнес-время может приходить за любой период - прошлое, настоящее или будущее

〉 Для одной бизнес-сущности не может быть двух значений данных в одно бизнес-время

Бизнес-время

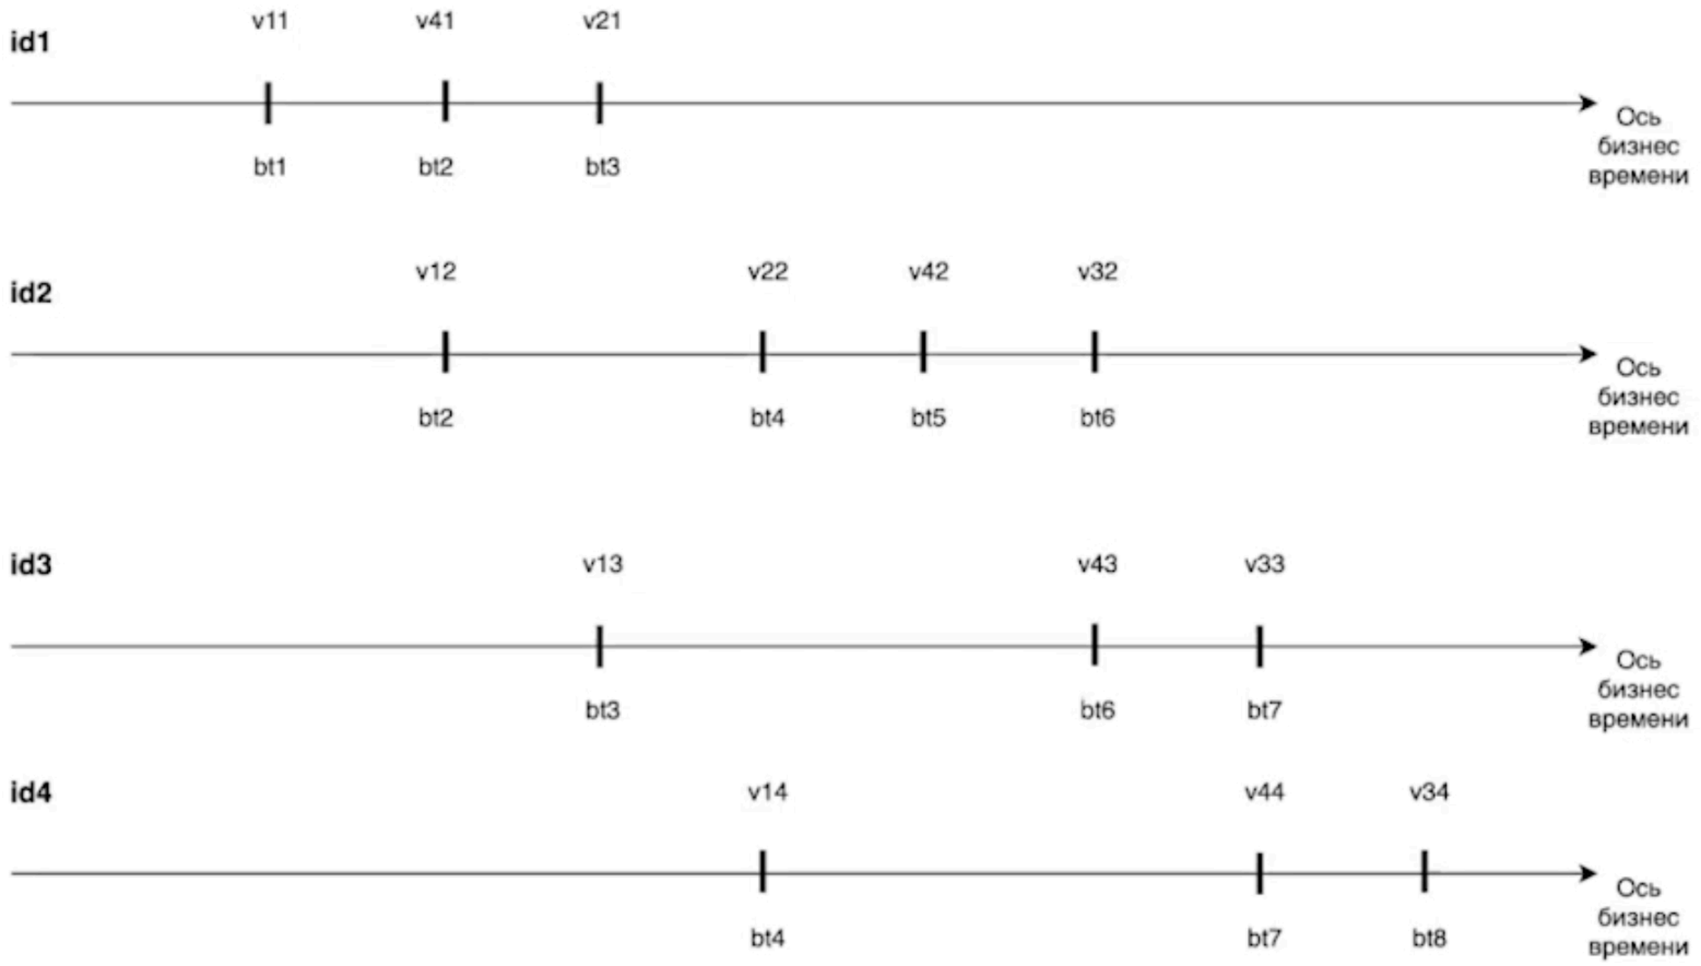

Техническое время

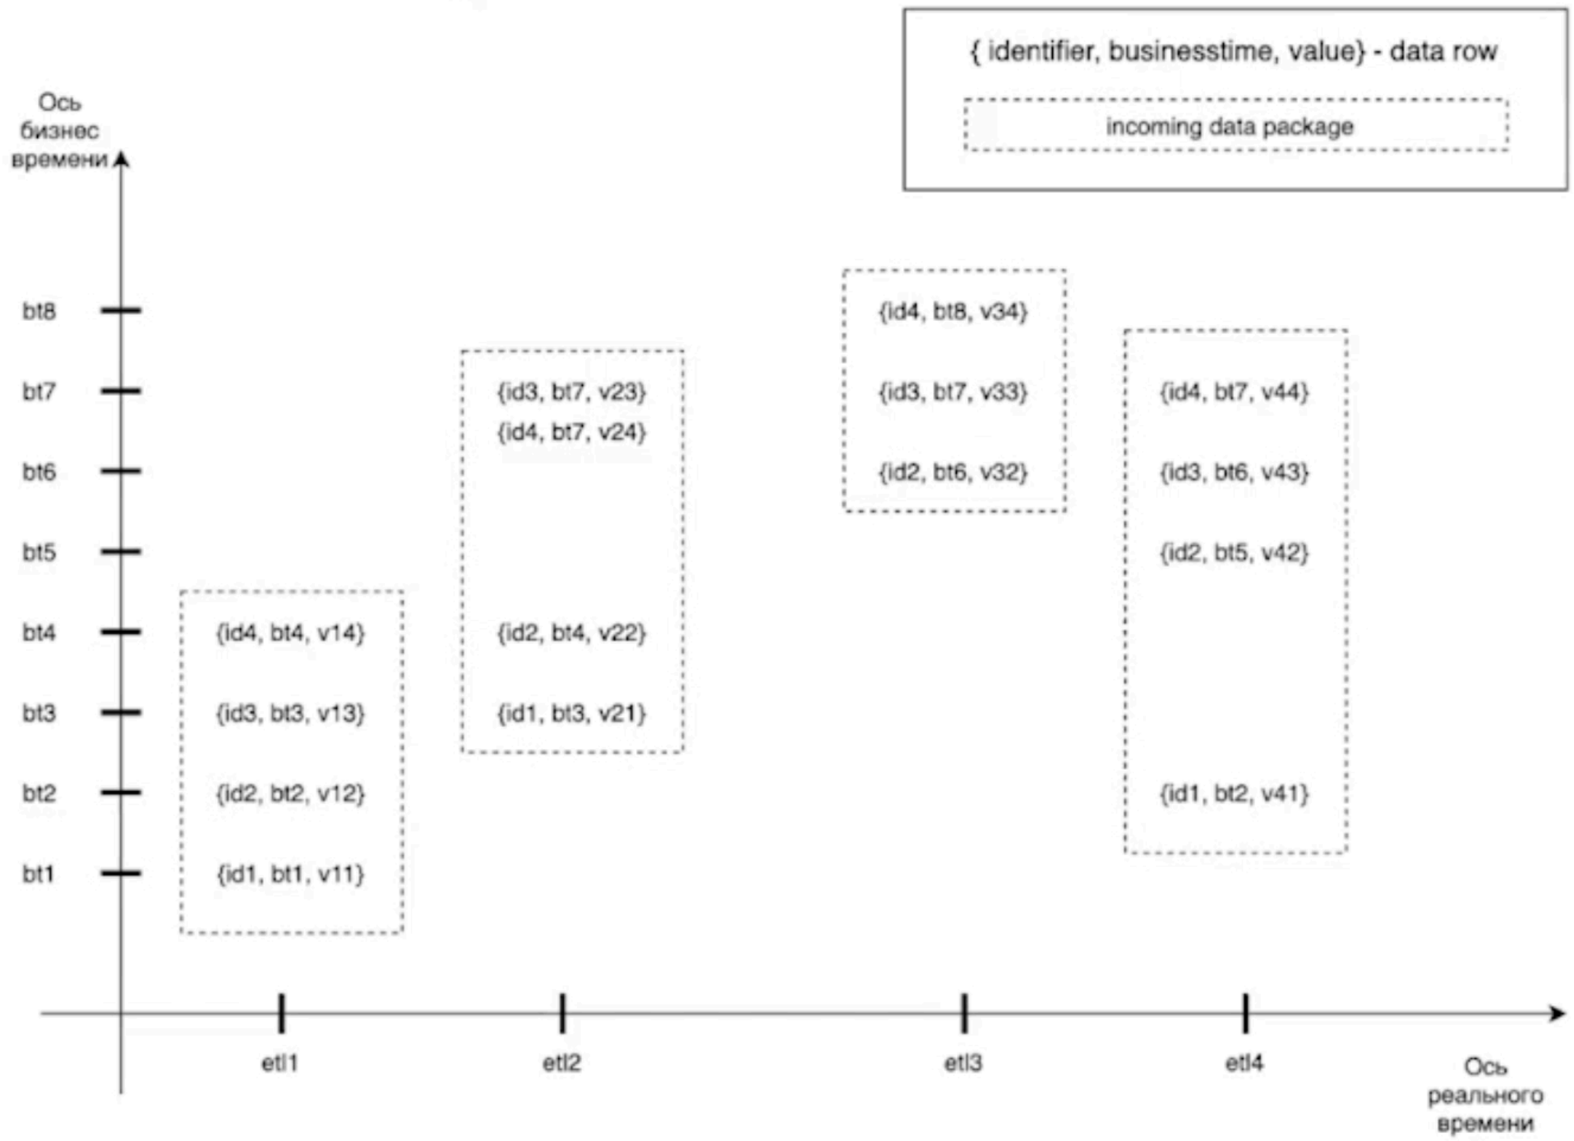

Как работает загрузка в DWH

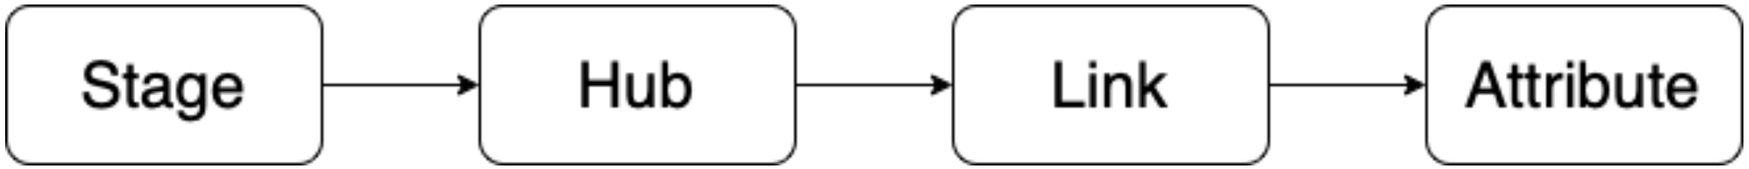

- Грузим данные в STG
- Генерируем суррогатные ключи для Hub
- Грузим Hub
- Грузим Link
- Грузим Attribute

Как работает загрузка в DWH

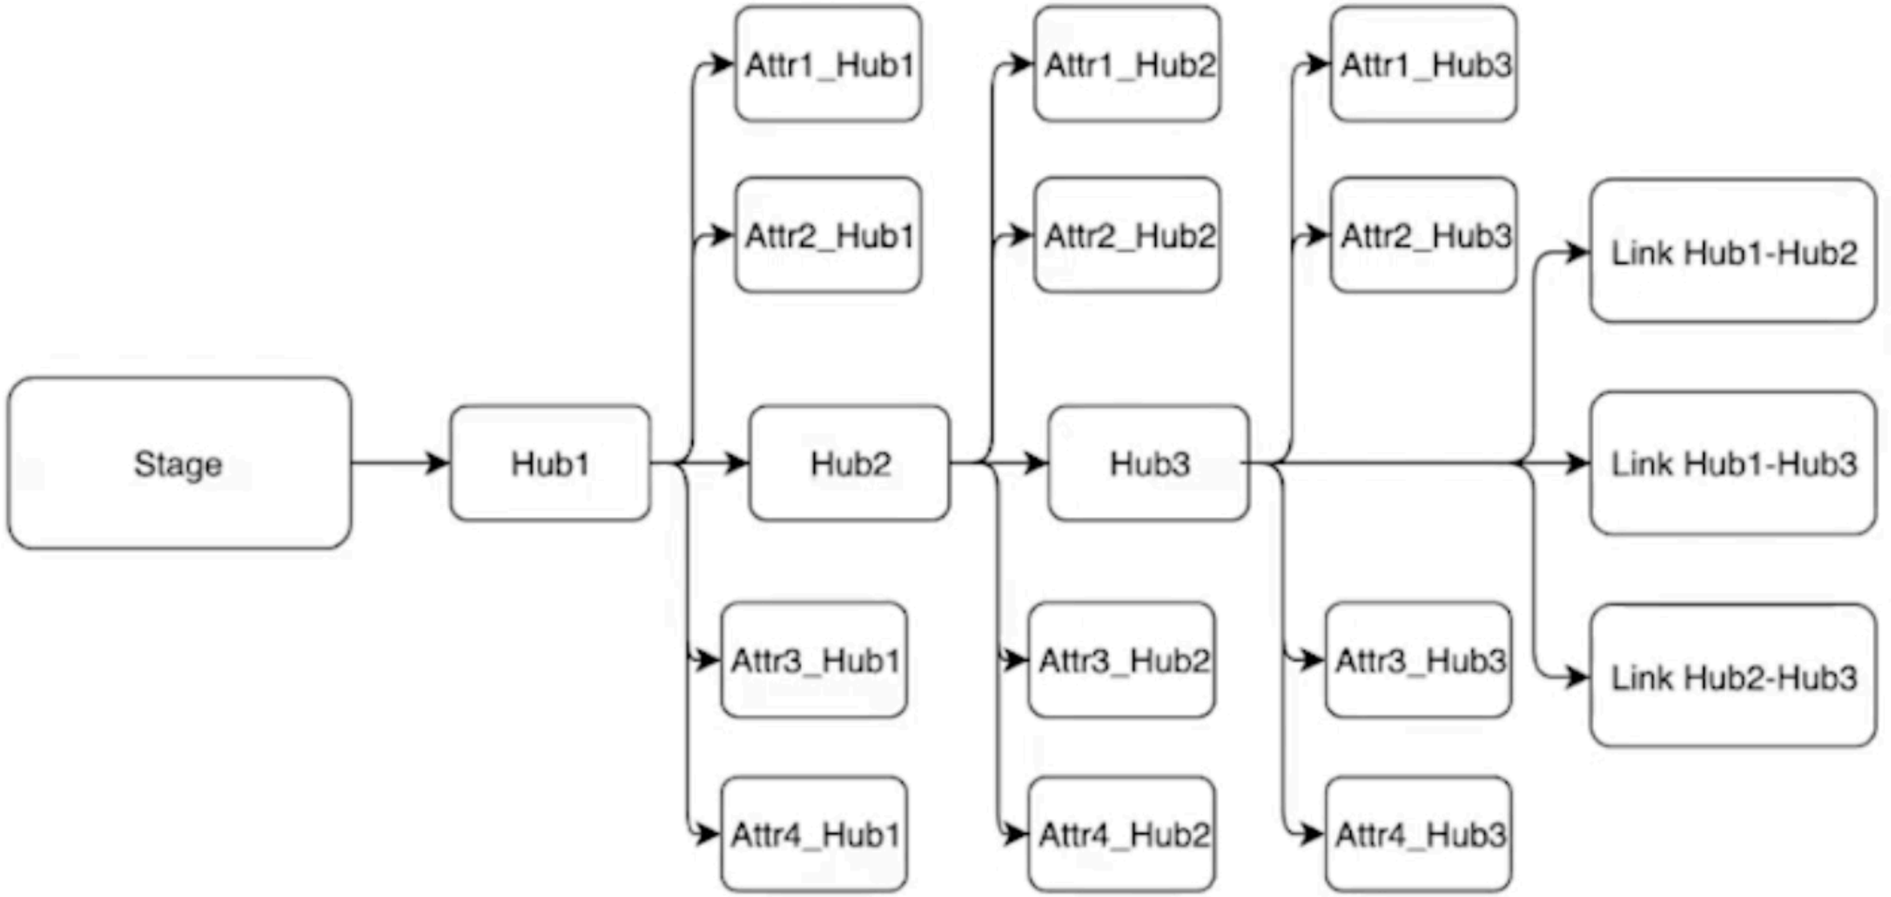

4 - Оркестрация

Мотивация

〉 Мы написали процесс, который везет изменения из источников к нам в целевую витрину

〉 Хотим сделать так, чтобы мы его не запускали руками, а он включался автоматически по какому-нибудь условию или расписанию

Crontab

〉 Системный daemon Linux
〉 Работает из коробки
〉 Может выполнять произвольную bash-команду по заданному расписанию

Crontab

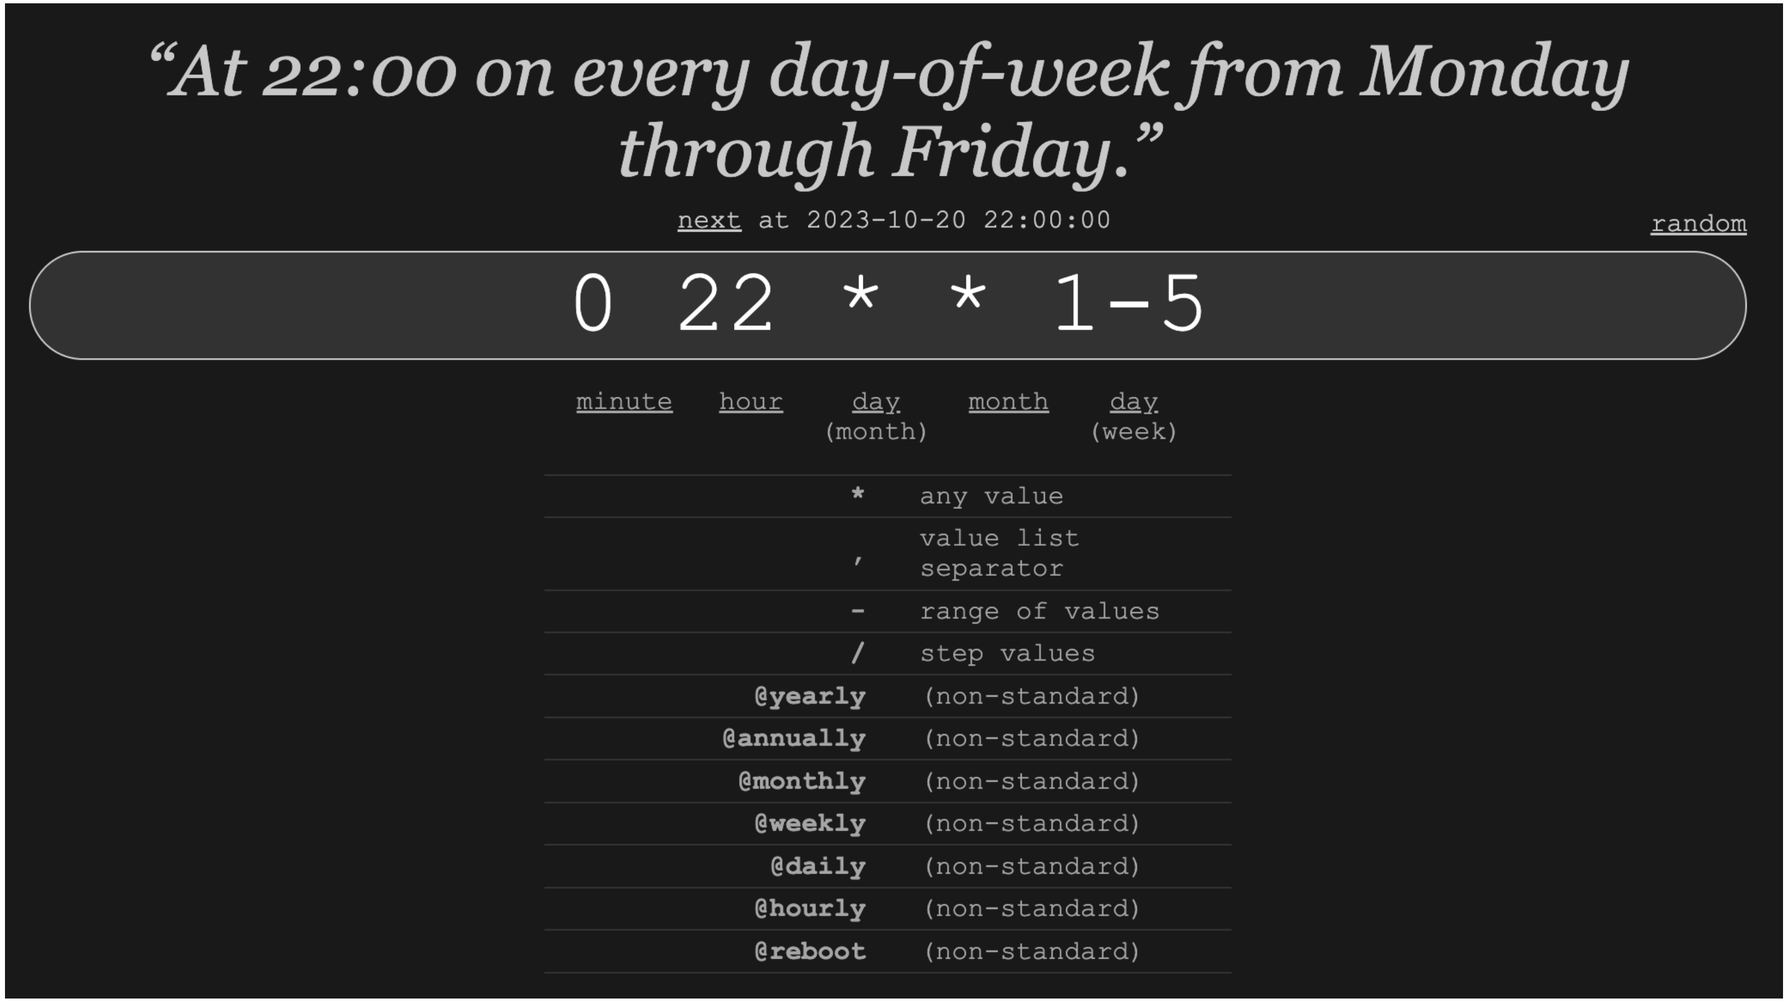

https://crontab.guru/

Crontab

Как с ним работать:

〉Команда crontab -e открывает файл с командами для cron (default /etc/crontab)

〉Каждая команда на новой строке, команда имеет вид:
* * * * * /path/to/exec

Crontab

Плюсы:

〉Простой и безотказный, как автомат Калашникова

Минусы:

〉Как и у автомата Калашникова, у него только одно простое применение, и больше он ничего не умеет

Что мы можем еще сделать?

- Запустить что-то в CI (GitHub CI, GitLab CI, Jenkins)
- Использовать проприетарный GUI-based ETL
  - MS SQL SERVER INTEGRATION SYSTEM
  - ORACLE DATA INTEGRATOR
  - INFORMATICA POWER CENTER
  - SAS DATA INTEGRATION STUDIO
- Написать что-то свое с нуля (обычно - обертка над Crontab, но есть Яндекс с его Nirvana / Reactor)

Вселенная opensource code-based ETL фреймворков

Apache

Spotify

Netflix

LinkedIn

Apache Airflow

Airbnb

Netflix

Kubeflow

Pinterest

Amazon

McKinsey

Apache Airflow

- Написали в 2014 внутри Airbnb
- 2016 - выпустили в OpenSource в рамках Apache Incubator
- 2019 - top-level проект Apache
- 2020 - Apache Airflow 2.0

Apache Airflow

- Написали в 2014 внутри Airbnb
- 2016 - выпустили в OpenSource в рамках Apache Incubator
- 2019 - top-level проект Apache
- 2020 - Apache Airflow 2.0
- **Сентябрь 2024** - релиз спецификаций к Apache Airflow 3.0

Почему именно он?

- Open source
- Великолепная документация (!)
- Простой код на Python
- Отличный Web UI
- Встроенные алерты и мониторинги
- Легко масштабируется
- Легко кастомизируется и дорабатывается
- Огромное комьюнити

Apache Airflow

DAG

DAG (Directed Acyclic Graph) - направленный ацикличный граф.

DAG объединяет отдельные задачи в единый Pipeline, в котором явно прослеживаются зависимости узлов друг от друга.

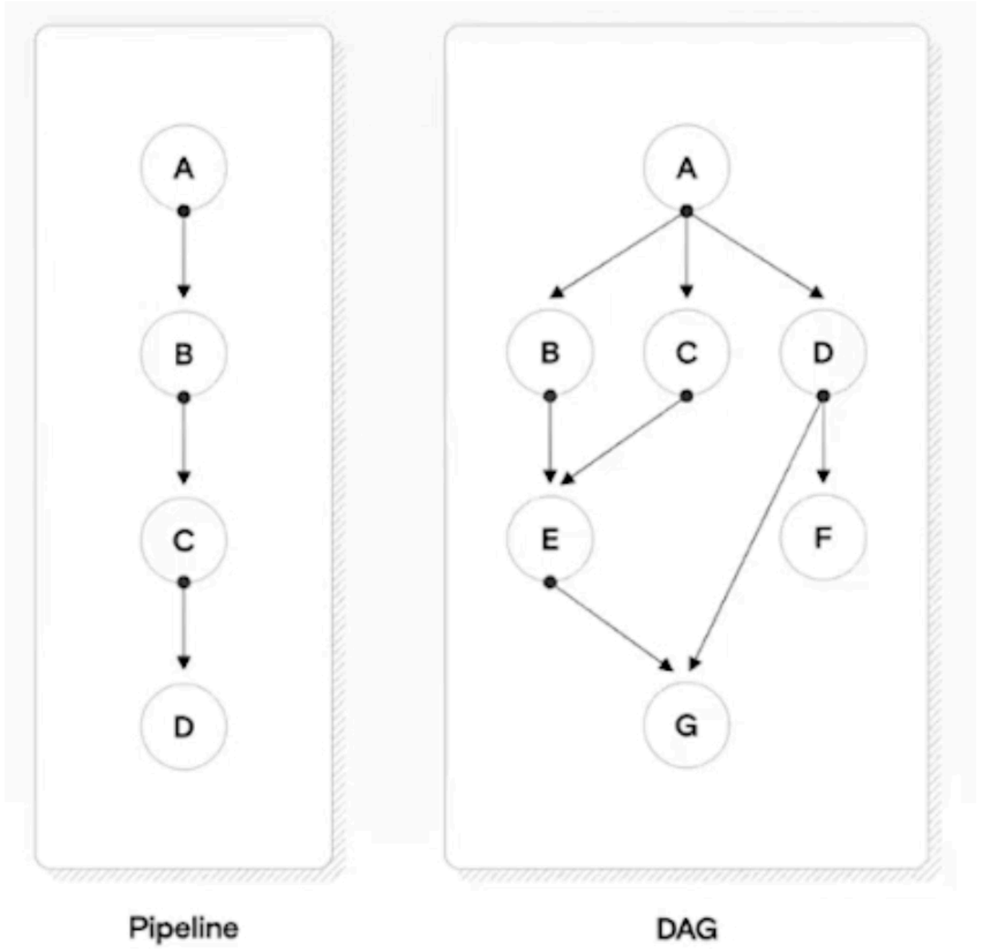

Виды операторов Airflow

Сенсор - внутри имеет произвольную функцию. Она выполняется в течение указанного времени, при падении/логическом “нет” запускается повторно через какое-то время. Как только эта функция возвращает логическое “да” - продолжает выполнение графа.
Пример: SqlSensor, PythonSensor и т.д.

Оператор - выполняет произвольное действие.
Пример: SqlOperator, PythonOperator и т.д.